



TransformerCVN: Transformadores de convolución para la clasificación de eventos y partículas NOvA

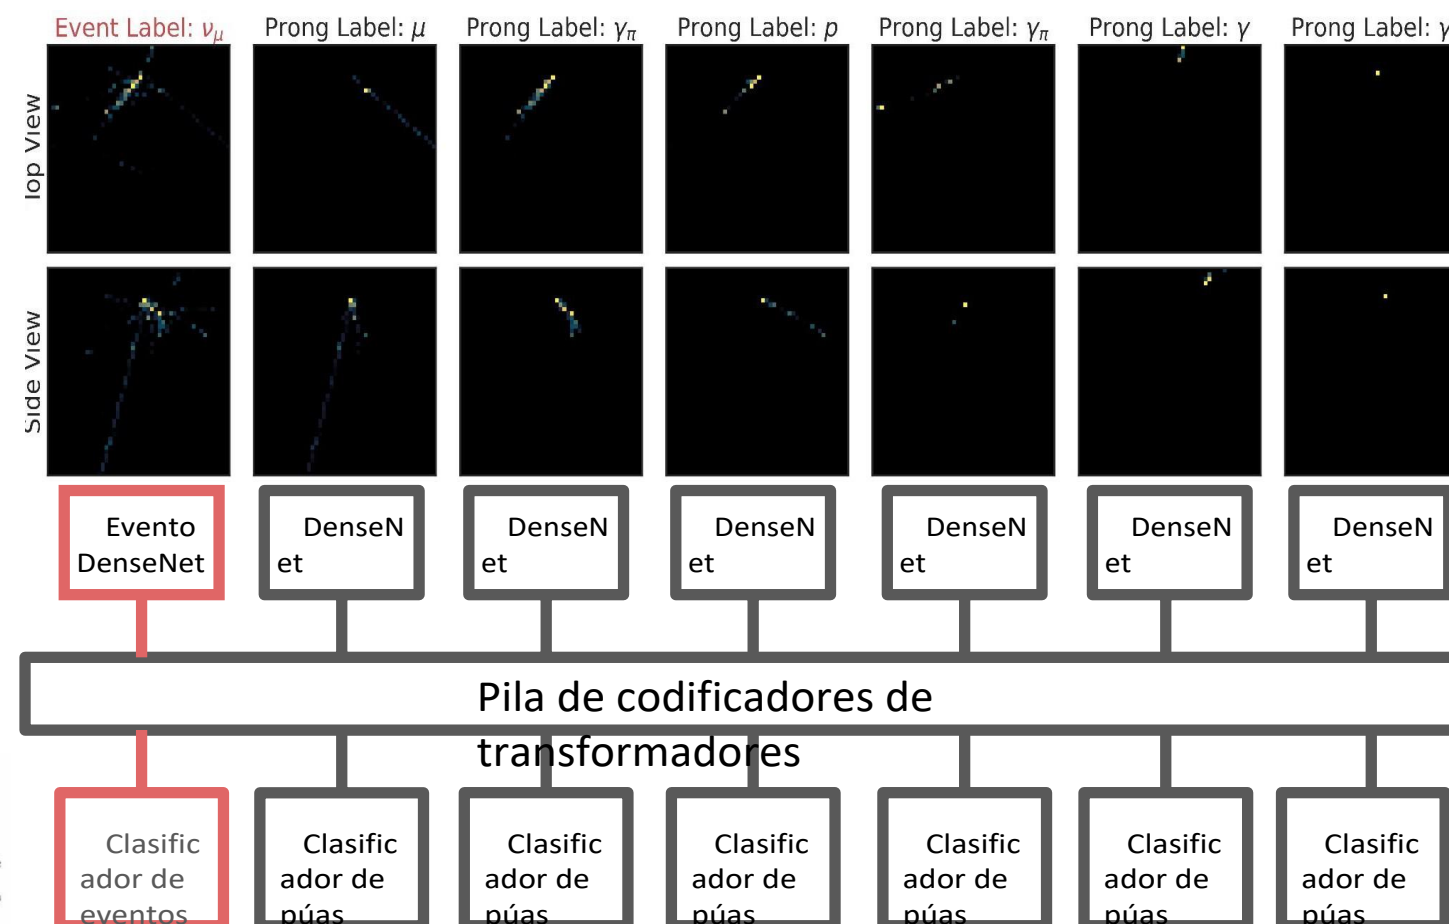
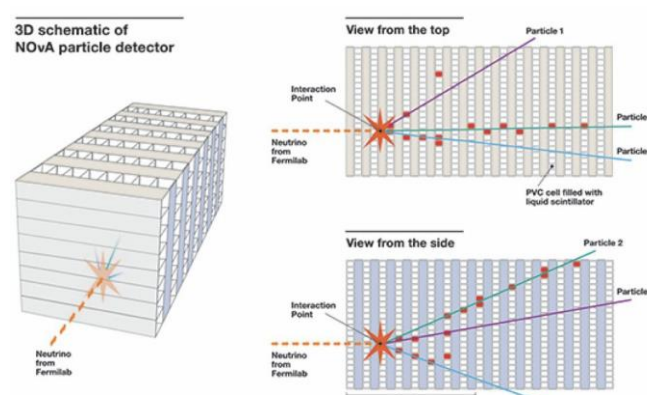

Antecedentes

NOvA es un experimento de oscilación de neutrinos de base larga que utiliza el haz NuMI del Fermilab [1]. El experimento consiste en dos detectores funcionalmente idénticos de 809 km de longitud formados a partir de extrusiones plásticas rellenas de un centelleador líquido.

El haz NuMI es predominantemente ν_μ . La colaboración estudia las oscilaciones de neutrinos detectando la tasa de desaparición de ν_μ y la aparición de ν_e en el detector lejano NOvA a través de las interacciones de corriente cargada. El objetivo de la reconstrucción de eventos es, por tanto, identificar el grupo de impactos de cada partícula en la célula de centelleo, conocido como "punta", y clasificar el tipo de interacción global del evento:

1. ν_μ corriente cargada (produce μ)
2. ν_e corriente cargada (produce e)
3. Corriente neutra (no se puede determinar el sabor)
4. Rayos cósmicos muones

Señal
Antecedentes




Un diagrama completo de *TransformerCVN*, incluyendo mapas de píxeles de ejemplo de un ν_μ evento actual. La *ruta del evento* independiente está resaltada en rojo. Las etiquetas de verdad para cada mapa de píxeles se proporcionan en la parte superior de la figura.

Result

EventoReconstrucciónTransformadorCVN pureza

1. Los eventos son preprocesados y recortados en una lista dos imágenes (xz y yz vista) cada una con un tamaño de 100×80 píxeles. Nos referimos a estas imágenes como *mapas de píxeles*.
2. Se genera un mapa de píxeles del evento que contiene todos los aciertos en el evento, así



Interpretabilidad

La arquitectura de extremo a extremo de TransformerCVN nos permite generar *mapas de calor* que indican las correlaciones entre las diferentes regiones de los mapas de píxeles y las etiquetas predichas por la red.

- Nos permite ver el razonamiento de la red detrás de las clasificaciones asignadas a determinados eventos.
- Permite interpretar qué aspectos de la entrada dan lugar a la predicción.
- Proporciona un método para analizar las reconstrucciones incorrectas.

A la derecha se presenta un ejemplo de mapa de calor para un ν_e evento actual.

- Regiones del mapa de calor que están en rojo

están correlacionados positivamente con la predicción de la punta de los electrones


- Las regiones azules tienen una correlación con la etiqueta de los electrones.

Los mapas de calor se generan mediante

1. Cálculo del gradiente de la salida de la clasificación de la punta de los electrones con respecto al mapa de píxeles de entrada [4],
2. Ponderación del gradiente mediante el mapa de activación de clases (CAM) [5] de las capas de convolución de DenseNet

no sólo los aciertos asignados a un solo prong utilizando la reconstrucción de prongs de NOvA.

3. Los mapas de píxeles se incrustan utilizando una *DenseNet* [3].
 - DenseNet consiste en una pila de capas de convolución con conexiones de salto entre todas las capas, lo que mejora la incrustación de los mapas de píxeles dispersos.



TransformadorC

En la actualidad se utilizan dos redes i.e. neuronales separadas entrenadas para la imagen, conocidas como redes visuales convolucionales (CVN), para las tareas de identificación de las partículas de las puntas y la clasificación general de los eventos [2]. Introducimos una arquitectura combinada de extremo a extremo para procesar y evaluar tanto el evento como todas las puntas asociadas en una sola red.

- Todos los mapas de píxeles de las puntas se alimentan a través de una única DenseNet compartida.
 - Para los mapas de píxeles de eventos se utiliza una DenseNet entrenada por separado.
4. Los mapas de píxeles incrustados se procesan a continuación mediante una pila de codificadores transformadores [6].
- Los transformadores facilitan la extracción de la información contextual sobre los dientes, procesando cada uno de ellos con respecto a todos los demás dientes del evento.
 - Esto permite que la información se comparta entre los prongs y que el lado del evento de la red tenga acceso a la información específica del prong.
5. Los mapas de píxeles codificados son procesados por clasificadores feed-forward para producir las predicciones de reconstrucción de los eventos y las puntas.
- Se utiliza un único clasificador compartido para todos los mapas de píxeles codificados.
 - Se utiliza un clasificador independiente para el mapa de píxeles del evento codificado.

Matriz de confusión para la clasificación de eventos en datos NOvA Monte-Carlo. El rendimiento coincide con el de la EventCVN especializada.

Curvas ROC de **reconstrucción de** prongs para la clasificación de prongs de electrones y muones y comparación de TransformerCVN con ProngCVN. La arquitectura unificada de extremo a extremo mejora la reconstrucción de los prongs con respecto a la ProngCVN al explotar la información contextual.

Simulación NOvA

Simulación NOvA

Simulación NOvA

3. Ponderar el gradiente por los pesos de atención de las capas del codificador transformador [6] para crear una lista completa de mapas de calor.

Referencias

[1] D. S. Ayres et al. Informe de diseño técnico de NOvA. 10 2007.

[2] A. Aurisano, *et al.* A convolutional neural network neutrino event classifier. JINST, volumen 11, P09001, 2016

[3] Gao Huang, Zhuang Liu, Laurens van der Maaten y Kilian Q. Weinberger. Redes convolucionales densamente conectadas. En las actas de la Conferencia del IEEE sobre visión por ordenador y reconocimiento de patrones (CVPR), julio de 2017.

[4] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh y Dhruv Batra. Grad-cam: Explicaciones visuales de redes profundas a través de la localización basada en el gradiente. En 2017 IEEE International Conference on Computer Vision (ICCV), páginas 618-626, 2017.

[5] Karen Simonyan, Andrea Vedaldi y Andrew Zisserman. Redes convolucionales profundas: Visualizando modelos de clasificación de imágenes y mapas de saliencia. En Workshop at International Conference on Learning Representations, 2014.

[6] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, L ukasz Kaiser e Illia Polosukhin. La atención es todo lo que necesitas. En I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan y R. Garnett, editores, Advances in Neural Information Processing Systems, volumen 30. Curran Associates, Inc., 2017.